



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика, искусственный интеллект и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ
НА ТЕМУ:

«Классификация известных методов определения
заимствований в исходных кодах программ»

Студент группы ИУ7-54Б

(Подпись, дата)

Чепиго Д.С.

(И.О. Фамилия)

Руководитель

(Подпись, дата)

Майков К.А.

(И.О. Фамилия)

2022 г.

РЕФЕРАТ

Расчетно-пояснительная записка 12 с., 1 рис., 0 табл., X ист., X прил.

КЛЮЧЕВЫЕ СЛОВА

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
1 Анализ предметной области	5
1.1 Области применения определения заимствований в исходных кодах программ .	5
1.1.1 Сфера образования	5
1.1.2 Контексты по программированию	5
1.1.3 Заимствования при разработке ПО	6
1.2 Критерии для определения является ли код плагиатом	6
1.3 Критерии сравнения методов определения плагиата	7
2 Обзор существующих решений	8
2.1 Text-based методы	8
2.2 Token-based метод	8
2.3 Metric-based метод	9
2.4 Tree-based метод	10
2.5 Binary-based метод	11
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	12

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

Введем понятия плагиат (от англ. *plagiarism*) – процесс или практика использования идей или работ другого человека и приписывания их себе [1]. В данной работе будем использовать слово плагиат как синоним слову заимствование.

Введем понятия контекст (от англ. *contest*) – соревнование, в котором каждый участник выступает без прямого контакта с конкурентами или вмешательства со стороны них [2]. Будем использовать словосочетание «контекст по программированию», как синоним к «соревнование по программированию».

ВВЕДЕНИЕ

Заимствование материала является распространенной проблемой как в сфере образования, так и в сферах научной и культурной деятельности. Зачастую это может повлечь за собой нарушение авторско-правового законодательства и патентного законодательства [3]. Соответственно, возникает необходимость установления авторских прав на интеллектуальный труд.

Основная область применимости проверки на заимствования исходных кодов программ – сфера обучения, а также соревнования по программированию. Это не только нарушает авторские права, но и отрицательно сказывается на качестве образования.

Цель работы – провести обзор существующих методов определения заимствований в исходных кодах программ. Для достижения этой цели требуется решить следующие задачи:

- провести анализ предметной области и обзор существующих решений;
- установить критерии для решения является ли программный код заимствованием;
- сформулировать критерии сравнения алгоритмов;
- классифицировать существующие методы определения заимствований в исходных кодах программ.

1 Анализ предметной области

1.1 Области применения определения заимствований в исходных кодах программ

1.1.1 Сфера образования

Академический плагиат – очень распространенное явление, рассмотрим его на примере университета. Иногда для определения заимствований не нужны специальные алгоритмы и автоматизированные системы, например:

- исходный код проверяется преподавателем в присутствии студента и акт заимствования можно определить при разговоре;
- в образовательных целях студенту необходимо реализовать уже существующий алгоритм, например, конкретную сортировку массива целых чисел. На такое задание заведомо есть верный ответ и решения студентов не будут сильно отличаться;
- количество студентов на курсе мало, преподаватель знает кто потенциально взял чужой код и может реализовать проверку вручную.

Также не всегда преподаватели считают, что плагиат это плохо, ведь иногда важнее понимание работы определенного кода, а не его реализация.

В остальных случаях, если преподаватели заинтересованы в выявлении плагиата, перед ними стоит задача найти оптимальный способ его определения, например – автоматизация проверки исходных кодов.

1.1.2 Контесты по программированию

На сегодняшний день существует множество различных соревнований по программированию, начиная от соревнования по самому запутанному коду на языке Си [4] и заканчивая крупнейшей международной олимпиадой по программированию ICPC [5]. Также контесты иногда проводятся при отборе на работу в крупные компании.

Плагиат в таких случаях зачастую играет решающую роль, ведь только на его основе можно определить уровень участника.

1.1.3 Заимствования при разработке ПО

Плагии при разработке программного обеспечения встречается намного реже, так как существует юридический документ, определяющий его использование и распространение – лицензия на программное обеспечение. Такие лицензии делятся на два типа: несвободные (исходный код закрыт) и свободные (открытое программное обеспечение). Их различия сильно влияют на права конечного пользователя в отношении использования программы.

1.2 Критерии для определения является ли код плагиатом

Опираясь на [6] были выделены 4 основных типа заимствования исходного кода:

- 1) Программный код скопирован без каких-либо изменений (идентичен оригиналу с точностью до комментариев).
- 2) Код скопирован с «косметическими» заменами идентификаторов (имен функций и переменных, типов данных, строковых литералов).
- 3) Код может включать заимствования второго типа и модифицирован путем добавления, редактирования или удаления его фрагментов или бесполезных участков кода. Также возможны изменения порядка, не влияющие на логику самой программы.
- 4) Программа некоторым образом переписана с общим сохранением логики работы и функциональности, однако синтаксически она может абсолютно отличаться от оригинала.

Заимствования четвертого типа крайне затруднительны для выявления, зачастую это приводит к нахождению плагиата алгоритмов, а не исходного кода. Так, например, в приведенном выше примере со студентами и сортировкой массива целых чисел, плагиатом будут считаться только заимствования первого типа.

1.3 Критерии сравнения методов определения плагиата

На основе приведенного выше анализа предметной области были выделены следующие критерии сравнения методов определения плагиата:

- 1) Поддержка нескольких языков программирования.
- 2) Определение каждого из типов заимствования.
- 3) Точность на небольшом объеме исходного кода.
- 4) Низкоуровневое сравнение кода (ассемблерный листинг или байткод).

2 Обзор существующих решений

2.1 Text-based методы

Text-based методы являются классическими методами для определения плагиата в обычном тексте, то есть не нацелены на программный код. Такие методы заключаются в сравнении текстовых представлений программ на основе таких метрик, как:

- расстояние Жаккара;
- расстояние Джаро-Виклера;
- расстояние Левенштейна;
- расстояние Колмогорова

В отличие от обычного текста, программный код нельзя маскировать с помощью замены кириллицы на латиницу, допущения орфографических ошибок или использовать изменение регистра (исключая строковые переменные).

Методы, основанные на сравнении текстов находят только заимствования первого типа. Такую проверку легко обойти, например, переименовав переменные и добавив свои комментарии. Такие методы не поддерживают несколько языков программирования.

Текстовые методы можно использовать для первоначальной оценки плагиата, так как они работают значительно быстрее, чем остальные [7]. Также, их можно применять при проверке небольших программных кодов, которые реализуют заведомо известный алгоритм. Потому что в таком случае единственный плагиат, который в нем можно найти – особенность структурирования кода и название переменных.

2.2 Token-based метод

Token-based метод основан на преобразовании ключевых слов программы в токены – последовательности лексических единиц с определенным значением.

Токенизация осуществляется по следующему алгоритму:

- 1) Каждому оператору языка программирования или группе операторов, имеющих схожее назначение, присваивается уникальный идентификатор. Назначения идентификаторов назначаются заранее и для всех классов операторов.
- 2) По полученным идентификаторам строится строка. В данной строке порядок токенов соответствует порядку следования их в исходном коде.
- 3) Полученные токены сравниваются любым доступным способом

Такой подход находит плагиат первых двух типов, также он может выявлять заимствованные фрагменты кода, которые расположены в различных местах программы, но делает это с неточностями. Поддержка разных языков программирования возможна только при использовании нескольких лексических анализаторов.

Методы, использующие токены, как и текстовые методы можно использовать для первоначальной проверки плагиата. Также если все программные коды, которые необходимо проверить на плагиат написаны на одном языке программирования и реализуют одинаковый функционал, то такой подход дает хорошую точность.

2.3 Metric-based метод

Metric-based метод дополняет token-based метод. Помимо сравнения токенов он на их основе определяет метрики, например:

- количество условных конструкций;
- количество используемых циклов;
- количество глобальных переменных.

Также зная специфику действий пользователей, можно выдвигать свои метрики, например – учитывать время обновления кода или количество пройденных с первого раза тестов, если они имеются.

На основе таких метрик высчитывается схожесть программных кодов. Такие методы достаточно легко обмануть, изменив структуру программы, например добавив лишние функции или пустые циклы. Все остальные характери-

ки аналогичны методу, использующему токены.

2.4 Tree-based метод

Tree-based подход основан на представлении кода в виде абстрактного синтаксического дерева.

Абстрактное синтаксическое дерево (англ. *Abstract Syntax Tree*) – конечное помеченное ориентированное дерево, в котором внутренние вершины сопоставлены с операторами языка программирования, а листья – с соответствующими операндами, то есть переменными и константами.

На рисунке 1 изображено дерево для выражения `while (x > 0) x = x - 1`.




Рисунок 1 – Представление структуры исходного кода в виде дерева

В таком формате программные коды сравниваются любым доступным способом. Таким образом, методы, основанные на абстрактных синтаксических деревьях состоят из двух этапов: построение деревьев и их анализ. Из наиболее популярных алгоритмов сравнения – алгоритм Zhang-Shasha, который позволяет вычислять редакционное расстояние между деревьями [8], или сравнение деревьев с помощью строковых ядер [9]. Таким образом можно выявить плагиат первых трех типов и осуществить поддержку нескольких языков программирования.

2.5 Binary-based метод

Данный метод сравнивает код после этапа компиляции или интерпретации [10]. В зависимости от специфики языка программирования, такой подход может показывать разную точность. При этом заимствования первых двух типов наблюдается высокая точность, так как компилятор часто оптимизирует мелкие структурные изменения, например, замена `for` на `while` и наоборот в подобных языках программирования. Также такой метод дает хороший результат при модификациях третьего и четвертого типа, но его также можно легко понизить, например, поменяв типы данных (хранить числа в строковом представлении).

Такой подход можно успешно использовать, когда все программы компилируются одинаково и имеют заведомо оговоренные типы данных. В таком случае можно определить заимствования всех типов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Cambridge dictionary [Электронный ресурс]. – Режим доступа: <https://dictionary.cambridge.org/> свободный – (12.12.2022)
2. Merriam dictionary [Электронный ресурс]. – Режим доступа: <https://www.merriam-webster.com/>, свободный – (12.12.2022)
3. Бобкова О.В., Давыдов С.А., Ковалева И.А., Плагиат как гражданское правонарушение // Патенты и лицензии. 2016. № 7. С. 31
4. The International Obfuscated C Code Contest [Электронный ресурс]. – Режим доступа: <https://www.ioccc.org/>, свободный – (12.12.2022)
5. Международная студенческая олимпиада по программированию [Электронный ресурс]. – Режим доступа: <https://icpc.global/>, свободный – (12.12.2022)
6. A Survey on Software Clone Detection Research, Chanchal Kumar Roy and James R. Cordy, 2007
7. Plagiarism: Taxonomy, Tools and Detection Techniques, Hussain A Chowdhury and Dhruba K Bhattacharyya, Dept. of CSE, Tezpur University, 2012
8. Zhang K., Shasha D. Simple fast algorithms for the editing distance between trees and related, problems // SIAM Journal of Computing, 1989. — No. 18. — Pp. 1245–1262.
9. Comparison of Abstract Syntax Trees using String Kernels, Raul Torres, Thomas Ludwig, Julian M. Kunkel, 2018
10. Semantics-Based Obfuscation-Resilient Binary Code Similarity Comparison with Applications to Software Plagiarism Detection, Lannan Luo, Jiang Ming, Dinghao Wu, Peng Liu, Sencun Zhu, The Pennsylvania State University